Detectando Fake News com Inferência Bayesiana

AUTHOR
Miguel Fiorin

Motivação: Identificação de Notícias Falsas (”Fake news”)

Com a proliferação de notícias nas redes sociais, torna-se essencial desenvolver filtros capazes de distinguir artigos reais de “fake news”. Com base em uma amostra de 150 artigos publicados no Facebook e verificados por jornalistas do BuzzFeed, este documento tem como objetivo calcular a probabilidade de um novo artigo ser falso, dado que apresentamos uma característica específica em seu título.

Estabelecendo Crença Inicial: Priori

Artigos Avaliados por Jornalista do BuzzFeed

Classe	Quantidade	Porcentagem
fake	60	0.4
real	90	0.6
Total	150	1.0

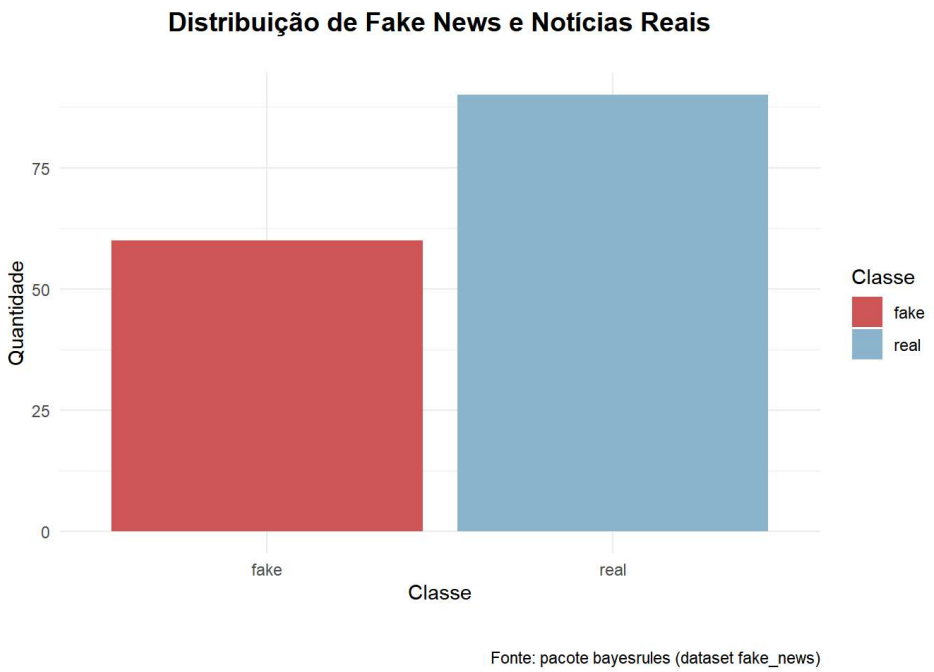

A partir dos dados coletados, contabilizamos os artigos classificados como *fake* e *real*, construindo uma tabela de frequências com as proporções de cada categoria. Além disso, apresentamos um gráfico de barras para visualizar a comparação entre as quantidades observadas.

Definimos o evento de um artigo ser falso como B. Com base nessa distribuição inicial, estabelecemos o modelo a priori da seguinte forma:

Modelo da Priori

$$P(B) = 0.4$$
$$P(B^c) = 0.6$$

Portanto, a interpretação dessas probabilidades é que, ao observarmos um novo artigo, atribuímos inicialmente uma probabilidade de 40% de ele ser falso, com base no conjunto de dados analisado.

A Evidência: o Uso de Pontos de Exclamação

Definimos o evento A como a presença de um ponto de exclamação no título do artigo. A partir do banco de dados, os artigos foram então classificados de acordo com duas dimensões: o tipo (*fake* ou *real*) e a presença ou ausência de ponto de exclamação no título.

O Uso de Exclamação e o Tipo de Artigo

Presença de Exclamação	Fake	Real
Não	44	88
Sim	16	2
Total	60	90

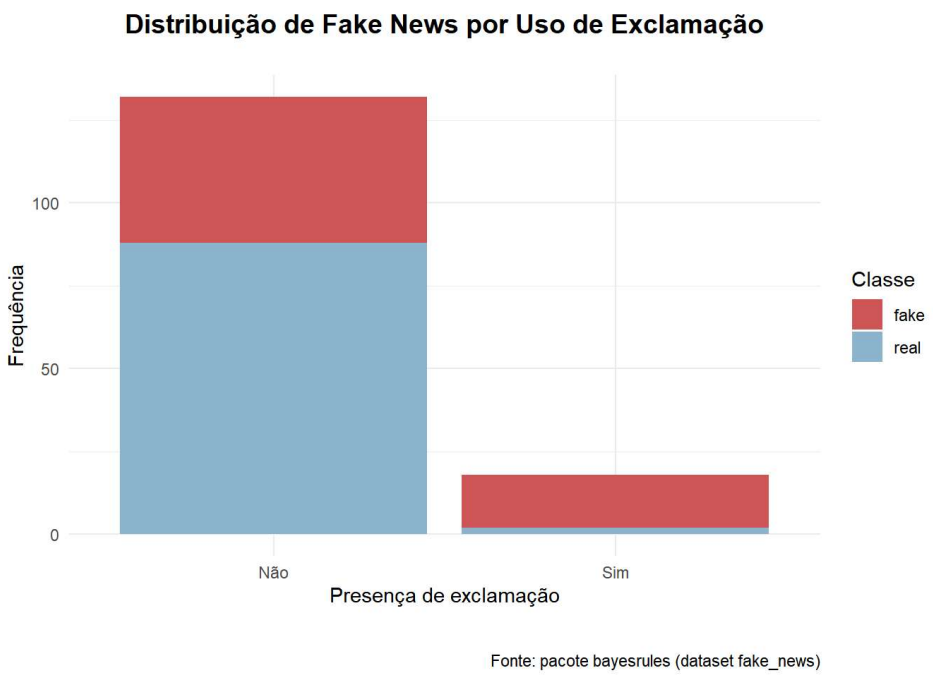

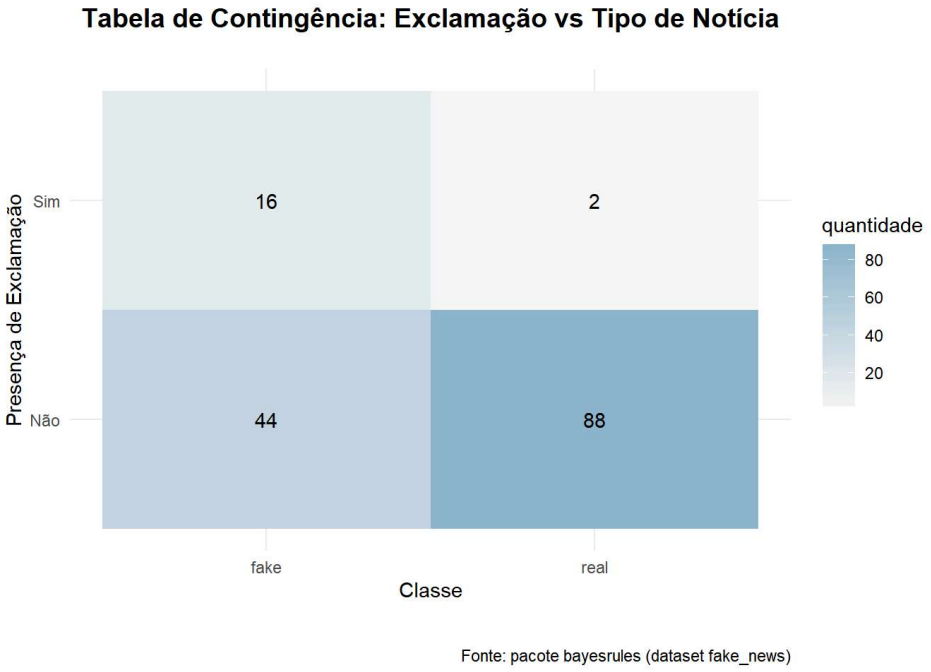

Com base na tabela e nos gráficos apresentados, observa-se que a presença de ponto de exclamação é mais frequente em artigos classificados como *fake*. O heatmap reforça essa evidência ao mostrar que a maior parte dos dados corresponde a artigos reais sem exclamação no título (88 de 150 observações), enquanto apenas 2 artigos reais apresentam exclamação.

A partir da tabela de contingência apresentada, é possível calcular a verossimilhança da evidência observada. Temos:

$$P(A \mid B) = 0.2667 P(A \mid B^c) = 0.0222$$

Esses resultados indicam que a presença de ponto de exclamação é significativamente mais provável em notícias falsas do que em notícias reais, dentro da amostra analisada.

Contruindo a nossa posteriori

Constante Normalizadora

A constante normalizadora é dada pela probabilidade de observar a evidência P(A)P(A)P(A). Para calculá-la, utilizamos a Lei da Probabilidade Total:

$$P(A) = \sum_{i=1}^{n} P(A \mid B_i)\, P(B_i)$$

Substituindo os valores obtidos:

$$P(A) = (0.2667 \cdot 0.4) + (0.0222 \cdot 0.6) = 0.12$$

Portanto, a probabilidade de observar a evidência A é de 12%, de acordo com os dados analisados.

Calculando a Posteriori:

Assim, com base no objetivo da inferência bayesiana, que consiste em atualizar a crença inicial a partir dos dados observados, buscamos calcular a probabilidade de um artigo ser *fake* dado a evidência

observada, isto é, a presença de um ponto de exclamação no título.

Aplicando o Teorema de Bayes, obtemos a probabilidade da classe do artigo condicionada à evidência observada:

$$P(B \mid A) = \frac{P(A \mid B)\, P(B)}{P(A)} = \frac{0.2667 \cdot 0.4}{0.12} = 0.889$$

$$P(B^c \mid A) = \frac{0.0222 \cdot 0.6}{0.12} = 0.111$$

Probabilidade da Priori e Posteriori

Evento	Fake	Real	Total
probabilidade priori	0.400	0.600	1
probabilidade posteriori	0.889	0.111	1

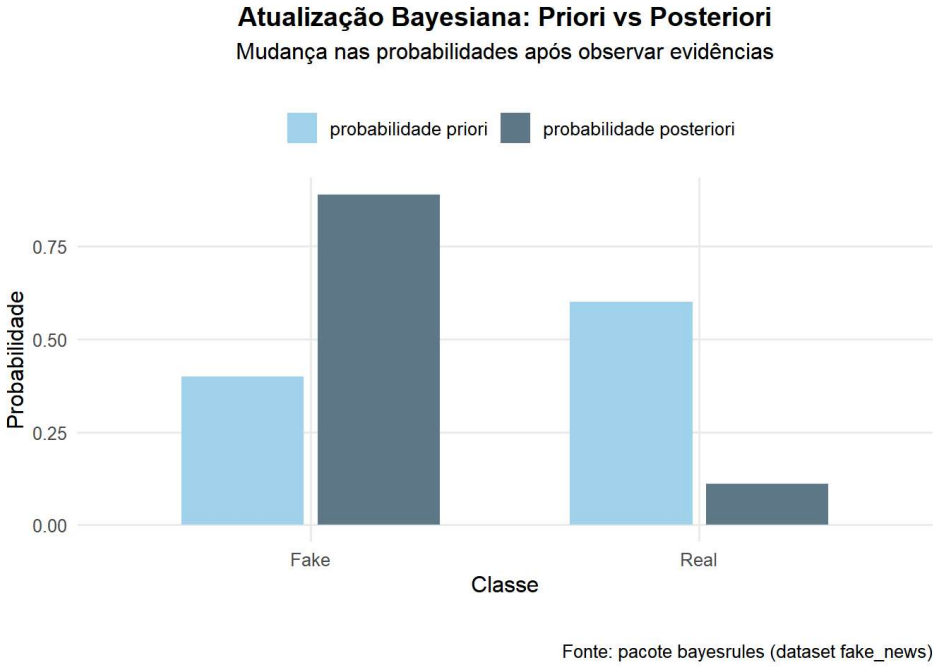

Conclusão

Ao construirmos um conhecimento prévio (priori) a partir da amostra analisada, nossa crença inicial era de que a probabilidade de um artigo ser *fake* ao selecioná-lo era de 40%. Após observarmos a evidência de que o título contém um ponto de exclamação, atualizamos essa crença por meio da inferência bayesiana.

A partir das probabilidades condicionais, obtemos a distribuição posterior (posteriori), que indica que, ao observar uma exclamação no título, a probabilidade de o artigo ser *fake* aumenta para aproximadamente 89%.

Dessa forma, a inferência bayesiana permite atualizar de maneira consistente nosso conhecimento inicial à medida que novas evidências são incorporadas.

Referências

JOHNSON, Alicia A.; OTT, Miles Q.; DOGUCU, Mine. *Bayes Rules! An Introduction to Bayesian Modeling*.

R Core Team. *R: A Language and Environment for Statistical Computing*.

Pacotes utilizados: tidyverse, bayesrules, kableExtra, janitor.